

讨论的问题：

0.核心研究问题的落点

1.任务边界如何界定

2.A的准入规则

3.核心contribution应该放在什么点上

4.对于下游ACT模型而言，什么是好的数据 如果ACT只是下游验证器那我们是否还应该关注这个问题；好数据是否需要既满足对于滤波器的“好”又满足对模型的“好”

5.根据5的答案反过来指导我们如何训练滤波模型

6.数据的契约是什么？

7.核心方法是什么？

8.实验怎么设计？

9.如果实验结果不如预期，如何降级claim和conclusion？

10.目前还有哪些名词、定义、结论和方法论需要继续找更多文献支撑和参考？

0.核心研究问题：

在固定安全边界下，基于任务有效遥操作示范自监督训练的上下文条件化因果命令滤波器，能否提高精密插入任务中单位操作者时间获得的任务有效示范产率？

Can a context-conditioned causal command filter, trained by self-supervision on task-valid teleoperation demonstrations, improve the yield of task-valid demonstrations per unit operator time for precision insertion under a fixed safety envelope?

Q1：固定安全边界/任务审计通过（什么是基于任务有效遥操作）的含义：满足对数据的基本要求，例如

有效任务配置

AND 完整因果记录

AND 成功完成插入

AND 无安全违规

AND 无未记录的外部接管

Q2:“精密”由什么定义：precision insertion 是常用术语，但没有统一阈值，需要提前声明公差和其他相关指标。（由已声明的有限几何容差和成功判据操作化）

Q3：上下文条件化怎么理解：同一手部抖动在自由接近、对孔和插入阶段的处理可以不同，这就是 context-conditioned。不能使用未来帧、最终成功标签或事后人工标注。

Q4：什么能称作“上下文条件化因果命令滤波器”：称作causal command filter更符合控制领域习惯，它在时刻 (t) 的输出只能依赖当前与过去的信息，不能看未来动作、未来图像或 episode 终

止标签。

Q5：fixed safety envelope包括哪些内容：

- 关节、速度、加速度和工作空间限制；
- 碰撞/最小距离约束；
- 急停和人工接管规则；
- 无视觉有效观测时的中止规则；
- 每轮允许的 reset 与安全中止处理方式。

Q6：提高高质量数据采集产率的话我们可以用一些客观的数据指标和下游模型的成功率来分开打分，这样也需要提前声明。这里的高质量数据也是一个需要讨论的核心点就是什么样的数据算高质量。

Q7：这个核心问题能不能再把其中的一些表达替换为有明确权威出处和定义的被更广泛使用的表达？

1.任务边界是什么：

Q1：对任务边界的定义应该从数据的角度还是模型的角度还是运动学/控制角度？数据。

任务边界的定义应该包括：公差、目标可见性、状态可观测性、无遮挡（这样规划器规划出的轨迹可以执行）、如果涉及到遮挡就会很复杂很难说清楚、传感器、数据的格式，并且要强调不是工业机器人的固定轨迹而是让模型能在生活场景里学会精密动作。并且要思考这类任务有没有人已经做过定义和概括。

我们采集的任务数据的边界：配置变化、目标单一且持续可见、参考可行的精密插入遥操作数据。(quality-audited teleoperation data for reference-feasible precision insertion in configuration-varying tabletop settings.)

（这里的配置包括：

- ($T_{\{WR\}}$)：receptacle 相对机器人/世界的位姿，例如笔记本和 USB-C 插口的位置、朝向。
- ($T_{\{WP\}}$)：待插入件的初始位姿，例如插头被抓取后的初始位置、姿态。
- ($T_{\{WE0\}}, q_0$)：末端和机器人初始构型，决定接近方向和可达性。
- (E)：桌面环境配置，例如笔记本位置、桌面上非阻挡物体、背景和照明。
- (K)：已标定的相机配置，例如固定相机/腕部相机的可用组合、视角或标定版本。)

一个任务属于该研究分布，当且仅当满足以下条件：

1. 明确的配合目标

存在一个待插入部件和一个匹配 receptacle；完成状态由相对位姿、插入深度、锁止/接触事

件或其他可观测条件判定。例如 USB-C 插头进入笔记本插座，RJ45 插头进入网口。

2. 有限且已声明的公差

预先声明插入 clearance、允许的平移/旋转误差、最大速度/加速度、碰撞和关节安全约束。超出范围的状态是 OOD，不要求系统解决。

3. 验证过的几何参考

对每个场景配置，在遥操作开始前，根据估计的目标几何生成并验证一条无碰撞、可达、满足机器人约束的几何参考轨迹。它只提供任务进度和质量审计坐标，不代表人的意图，也不要求滤波器强制追踪它。

4. 目标持续可见、状态可观测（怎么考虑暂时遮挡，或者说对谁可见？）

插入关键区域在执行中保持可见；不研究目标遮挡、重定位、盲插或传感器失效。机器人状态、执行命令和所声明的视觉观测必须持续可获得并完成时间同步。

5. 存在无碰撞执行通道

当前配置下存在 collision-free approach corridor。视觉无遮挡与运动无障碍分开验证；不把障碍规避、未知杂物或全局重规划混入研究问题。

6. 非固定工位的受控配置变化

任务不局限于一个固定夹具、固定目标位姿和固定起点。目标位置/姿态、桌面布局、相机视角、照明或接近配置在预先声明的范围内变化。

这意味着“生活化桌面配置变化”，不是声称任意家庭环境泛化。

2.A的准入规则是什么？

backup:如果我们的方案没法让新模型达到声称的质量提升效果，那么能不能在无模型的前提下衡量数据质量的提高或者采集效率的提高：我自己的观点是如果模型能力不够好那么声称的数据质量高也没有太大意义，但现在是否有客观标准能在不涉及模型的情况下就能判断数采轨迹的质量呢，也是有的。

或者说，在任务边界的界定上，我们的侧重点应该更多地放在模型上还是数采上？只放在运控上一定是不行的，因为传统方法就可以解决纯运控问题比model based方法更好。

2.1 原始数据的保留策略是什么？

2.2 A_action 的最小准入规则是什么？

2.3 A_audit 的标签体系是什么？

2.4 A_action 如何保持配置覆盖而不只收集容易样本？

2.5 如何评价采集效率与数据效用？

2.6 如何防止质量门与模型形成自我强化？

它们的依赖关系是：

任务边界

-> 数据契约

-> 原始数据与 audit 标签

-> A_action 准入

-> buffer 覆盖约束

-> 训练 F

-> 采集效率 / 下游效用评测

2.1 原始数据保留策略

所有 trial 都保留原始 rosbag 和 episode manifest。不能因为失败、遮挡或急停就物理删除数据。

这回答的是“数据是否可审计”，不是“它是否高质量”。

2.2 A_action 的最小准入规则

核心布尔逻辑：

valid configuration

AND complete causal record

AND successful terminal insertion

AND no safety violation

AND no unlogged external override

它的目标仅是保证：该 episode 能作为学习型滤波器的正向动作样本。

不应在这里加入 jerk、完成时间、覆盖度、冗余或人工评分。否则会变成手工质量分数。

2.3 A_audit 的标签体系

所有未进入 A_action 的数据不能简单叫“坏数据”，要有排他标签：

reference_invalid

visibility_invalid

record_incomplete

safety_abort

external_override

task_failure

successful_safe_return

out_of_distribution

其中 successful_safe_return 对安全分析有价值，但不是“成功插入”的正向模仿样本。

2.4 数据集覆盖约束

这是 dataset-level 问题，不是 episode-level quality。

在每个预声明配置单元中报告：

attempted
eligible for A_action
successful
rejected by reason
operator active time

并预先设定最低覆盖要求或采样配额，防止模型只在最容易的插口位置、起始姿态和照明下采到成功轨迹。

2.5 采集效率与数据效用的评价

这是论文结果，不应反过来定义 A_action。

主结局：

A_action episode 数 / 操作者主动时间

守门结果：

all-attempt task success rate
all-attempt safety-event rate

数据集报告：

配置覆盖、冗余、拒绝原因分布

机制诊断：

延迟、跟随误差、必要微调保留情况

ACT 的 held-out 成功率若做，是最强的下游效用验证，但应单列为 secondary study，不要和采集产率合成总分。

2.6 防止自我强化

单列的问题。需要四条规则：

- A_action 的准入逻辑在首次模型训练前冻结；
- 准入只依赖任务完成、安全、记录完整性和已声明配置有效性，不依赖模型预测分数、jerk 或滤波器自身输出质量；
- 所有尝试都进入 audit 分母，不允许只报告筛选后成功数据；
- 按配置单元报告并设最低覆盖，避免模型通过只完成简单样本提高接受率。

但我们如果先定义指标再训练有可能变成自我强化而且有手工特征工程的感觉。所以应该见根据我们想要证明的因果主张然后再推出最少的指标，每个指标都要有明确的决策用途

现有文献没有给出脱离任务和下游用途的统一遥操作数据质量标量；我们不提出一个普适 score，而为可见、参考可行的精密插入定义一个可审计的训练准入契约，并通过跨轮采集结果验证其效用。

3.核心contribution是什么：

我们的三个contribution必须回答核心问题的三个子问题：

哪些任务、哪些数据？

如何从这些数据学习过滤器？

它是否真的让后续采集更有效？

1. 任务化的采集与数据准入契约(工程贡献)

我们针对“已抓持、目标持续可见、参考可行、配置变化的精密插入”定义采集任务分布，并提供一个可审计 episode contract：原始遥操输入、过滤命令、实际执行状态、视觉观测、参考进度、场景配置、成功和安全事件在统一时间轴上记录。

该契约通过透明的 A_action 准入逻辑区分可用于正向动作学习的数据与 A_audit 中的失败/中止数据。

回答：哪些任务和哪些真实遥操数据可用于学习？

注意不声称提出了全新的 insertion task；贡献是为这个采集闭环提供了可复现、可执行的任务化数据协议。

2. 质量门控的自监督上下文条件化因果命令滤波器（研究性质的贡献）

我们提出一个从 A_action 中自监督学习的命令滤波器。它以原始遥操输入历史、机器人状态、目标相对状态和参考进度为上下文，学习高质量执行动作的时间结构；在线时以有界方式去噪或修正人类命令，始终经过固定安全投影。

它不预测人类意图，不输出不受约束的自主策略，也不将规划轨迹直接当作动作教师。

回答：如何把任务有效的真实数据转化为一个可部署的人机协同滤波器？

3. 固定资源下的跨轮数据飞轮验证（研究性质的贡献）

我们在相同操作者主动时间、reset、场景配置和安全边界下，比较规则滤波、一次性训练滤波和迭代训练滤波。主结局是单位操作者时间获得的 task-valid 示范数；同时报告 all-attempt 成功率、安全事件、配置覆盖、数据冗余及命令保真度。

可选的下游 ACT study 使用相同训练配置，验证 F_flywheel 收集的数据是否带来更高的 held-out 插入成功率。

回答：该闭环是否真的提高了数据采集效率，而不是只让动作更平滑或只收集更容易的样本？

Q1：没有失败接管和失败恢复机制是否真正算数据飞轮？

Q2：这个滤波模型的输出和下游模型的好数据定义需要有多大联系？

Q3：在这个特定集合下能否找出和我们方向差不多的论文参考？

Q1：没有失败接管和失败恢复机制，是否仍然算数据飞轮？

可以。数据飞轮的必要条件是“本轮采集的数据改变下一轮的数据生成器”，而不是必须包含失败恢复或人工接管。JUICER (IROS 2024, [arXiv:2404.03729](https://arxiv.org/abs/2404.03729)) 将成功 rollout 回流训练并迭代收集，说明 success-only 的 $D_t \rightarrow F_{t+1} \rightarrow D_{t+1}$ 已构成数据闭环；它不等同于 failure recovery，也不证明物理遥操作场景中的安全性。

因此本文可以称为“quality-gated iterative data flywheel”，但要明确边界：

- A_{action} 的成功轨迹训练下一代滤波器；
- A_{audit} 中的失败、急停、遮挡和外部接管仍保留，用于审计、风险统计和诊断，但不作为正向动作样本；
- 每轮必须报告所有尝试作为分母，不能只报告回流后的成功样本；
- 若没有失败恢复，不能声称解决了 recovery intervention learning 或 autonomous recovery。

这一区分也受到 Sirius / Robot Learning on the Job (RSS 2023, [论文](#)) 和 PATO (RSS 2023, [论文](#)) 的限制：它们已经研究了接管、策略辅助和持续数据收集，所以本文的飞轮新意不能写成“首次利用接管改善数据”，而应落在任务审计准入、因果滤波和固定资源下的跨轮产率验证。

Q2：滤波器输出和下游模型的“好数据”定义需要多大联系？

需要有**契约层面的联系**，但不应有逐步标签或训练目标上的强耦合。滤波器直接学习的是：在任务上下文和历史观测下，哪些执行动作与已成功、完整、无安全违规的 episode 相容；下游 ACT 只验证这些数据是否对另一种策略学习器有用。

两者的关系可分成三层：

1. **必须共享的底层契约**：观测与实际执行动作时间对齐、终止和安全事件可信、配置身份可追溯、关键视觉和机器人状态不缺失。这些条件同时是 A_{action} 和 ACT 样本的最低有效性要求。
2. **滤波器特有的要求**：保留原始遥操输入、滤波输出和实际状态的因果链；在线只能用当前及历史信息；不确定或 OOD 时回退到固定安全滤波。ACT 不需要原始人类输入，因此不能反过来决定滤波器的监督信号。
3. **数据集级下游要求**：配置覆盖、近重复率、必要微调动作和 held-out 切分。这些用于评价数据集效用，不能事后作为单条成功 episode 的准入分数，否则会形成模型偏好驱动的自我强化。

因此，ACT 成功率应是 secondary construct-validity test，而非滤波器的 reward。ALOHA/ACT（RSS 2023, [arXiv:2304.13705](#)）证明 action chunks 可从遥操示范学习，但没有给出通用 trajectory-quality score；本文应保留这种“下游效用验证、训练准入解耦”的关系。

Q3：是否有与本文方向相近的论文？

有相邻工作，但尚未发现同时覆盖“配置变化的精密插入、任务审计准入、自监督因果命令滤波、固定资源跨轮产率”四项的论文：

工作	相似点	关键差异与本文不能重复声称的内容
PATO, RSS 2023, 论文	policy-assisted teleoperation、降低操作者负担、提升数据收集效率	已覆盖 generic policy-assisted teleoperation；本文需聚焦精密插入的任务契约和跨轮 filter flywheel。
Sirius / Robot Learning on the Job, RSS 2023, 论文	部署中持续收集人类动作并更新策略，使用 intervention 作为质量线索	目标是 intervention-driven policy learning，不是成功遥操 episode 训练命令滤波器。
DPIIL, RA-L 2024, DOI	根据操作者速度/方差和不确定性处理精度需求	分数用于 query/intervention，不是 episode 准入契约或数据飞轮主结局。
JUICER, IROS 2024, arXiv	成功数据回流、迭代训练、数据效率评估	主要是仿真家具装配和 bottleneck/synthetic augmentation；不涉及物理遥操滤波和可见精密插入。
OEC-IRRL, Frontiers in Neurorobotics 2024, DOI	半结构化/fixture-less assembly、变化的物体位置、object-frame 表征	研究重点是装配策略与表示，不是采集协议、质量门控或滤波器闭环。

本文最稳妥的 novelty 表述是：不是提出新的 insertion primitive，也不是首次做 policy-assisted teleoperation，而是把这些相邻机制组合成一个可审计、可复现实验的精密插入数据采集闭环，并用固定操作者时间、reset、配置和安全预算检验它是否提高 task-valid episodes / active operator minute。

4.在这类特定任务下，对ACT一类模型什么是好的数据

Q1：benchmark / imitation-learning 论文是否单独评估数据质量？

有，但结论不是“存在一个可迁移的统一质量分数”。近年的工作通常将 data quality 操作化为三类不同问题：示范能否完成任务、数据分布是否足以覆盖评测配置、以及固定下游学习器能否从中学出可执行策略。它们不应混成一个 episode-level score。

工作	论文与链接	它实际如何处理数据质量	对本文的含义
ALOHA / ACT (RSS 2023)	Zhao et al., Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware	以真实遥操示范训练 action-chunking policy，并用任务成功率评估数据加模型后的结果；未提出可脱离任务的遥操轨迹质量分数。	ACT 成功率可作为固定、冻结的 secondary downstream utility test，不能定义 A_action，也不应作为滤波器的训练监督。
PATO (RSS 2023)	Mandlekar et al., Policy-Aided Teleoperation for Scalable Robot Data Collection	用 policy assistance 改善收集效率，实验关注任务成功、收集时间和人类工作负担，而不是以一个普适轨迹质量标签筛除数据。	人时和任务成功是已有的采集系统结局；本文的新处应是 task-audited gate、因果滤波和固定资源的跨轮比较，而非泛称“更高质量数据”。
Sirius / Robot Learning on the Job (RSS 2023)	Mandlekar et al., Robot Learning on the Job: Human-in-the-Loop Autonomy and Learning During Deployment	将失败前 intervention 视为低质量自主执行的信号、将人类动作视为高质量监督，并以加权 BC 持续更新策略。	不能声称“接管/干预可判断数据质量”为新意；我们的区别必须是成功插入的完整因果遥操记录如何训练 filter，而不是为自主策略收集纠正动作。
DPIIL (RA-L 2024)	Zhu et al., DPIIL: Dynamic Precision-based Imitation Learning	用操作者速度和方差表征人感知的精度需求，并结合 policy uncertainty 决定何时请求专家。它的分数是 query / intervention rule，不是 episode 准入标准。	速度、方差、jerk 可以用于机制诊断，不能单独定义“好示范”或进入 A_action 的门。
JUICER (IROS 2024)	Zaidi et al., JUICER: Data-Efficient Imitation Learning for Robotic Assembly Through Quality-Aware Data Collection	通过识别瓶颈、生成辅助数据并将成功 rollout 回流训练，评估下游完成率与数据效率；场景是仿真家具装配。	支持“迭代数据闭环可只以成功数据回流”，但不证明物理遥操 filter、精密插入或配置覆盖不会塌缩。

因此应作如下可证伪的表述：在本任务分布内，A_action 是可用于学习 filter 的合格因果记录，而不是普适的“高质量数据”定义；其质量主张由固定资源下的采集产率和一个冻结的下游学习协议共同检验。即使 ACT 结果没有提升，A_action 的可审计性与采集产率仍是独立可报告结果；但不能据此宣称它对所有策略模型都“更好”。

对 ACT 而言，好的数据至少应满足：

- observation 与 executed action 时间对齐，且动作是实际执行后的命令/状态，而不是原始人类输入；
- 终止、成功和安全语义可靠，训练与 held-out 配置切分预先固定；
- 覆盖声明的 receptacle pose、初始相对位姿和视觉条件，且不被少数容易配置的近重复轨迹主导；
- 对插入阶段保留必要的微调、退回和接触前减速，而不是仅具有低 jerk 或最短完成时间。

这些要求中，前两项是 sample-validity，后两项是 dataset-level adequacy；后二者不能用来回溯地拒绝一个已成功的 episode。

Q2：这如何反过来指导滤波模型训练？

它指导的是**训练目标与约束**，不是把 ACT 成功率反向当作每一步的监督标签。滤波器的直接目标应是从 A_{action} 的完整因果记录中预测、在当前任务上下文下与成功执行相容的局部动作先验；ACT 只检验该数据对另一类学习器是否仍有用。

设 $u_{\{ \leq t \}}$ 为原始遥操命令历史， $x_{\{ \leq t \}}$ 为机器人状态历史， $c_{\{ \leq t \}}$ 为相对目标状态、参考进度和有效视觉特征， a_t^{exec} 为实际执行的笛卡尔命令。可训练：

$$p_{\theta}(a_t^{\text{exec}} \mid u_{\{ \leq t \}}, x_{\{ \leq t \}}, c_{\{ \leq t \}})$$

或其 masked-action / next-action reconstruction 形式。这是 A_{action} 内部的自监督序列学习：执行动作来自同一条已审计的记录，而成功/失败标签只决定该 episode 是否进入正样本池。因此整个系统不是“无监督”，而滤波器的动作表征学习可以称为 self-supervised。

在线输出不应成为不受约束的自主策略。推荐形式为：

$$a_t^{\text{cmd}} = \text{Pi_safe}((1 - \lambda_t) F_{\text{rule}}(u_t) + \lambda_t F_{\theta}(u_{\{ \leq t \}}, x_{\{ \leq t \}}, c_{\{ \leq t \}}))$$

其中 Pi_safe 是固定安全投影， λ_t 有界并在不确定性高、可见性失效或 OOD 时退回规则滤波。它把下游数据需求转为四项可验证的滤波训练约束：

- 因果可追溯：只使用部署时可获得的历史；训练目标必须是 executed action，不能泄漏未来帧或终止标签。
- 任务上下文文化：输入含相对目标状态/参考进度，使接近、对孔、插入阶段对同一抖动采取不同处理；参考不是动作教师。
- 保真而非过平滑：报告与原始输入的偏离、延迟及微调保留，避免为低 jerk 抹掉对孔、退回等有效动作。
- 覆盖与保守性：按预声明配置单元均衡抽样或重加权；OOD、遮挡或不确定性上升时固定后退，防止只在容易配置上提高 A_{action} 产率。

最终关系应保持单向： $A_{\text{action}} \rightarrow \text{train } F_{\theta} \rightarrow \text{collect } D_{\{t+1\}}$ ；冻结的 ACT study 只在每轮结束后评价 $D_{\{t+1\}}$ ，不参与 A_{action} 准入，也不对每条遥操轨迹提供训练奖

励。这避免了用下游模型偏好自我强化筛选规则。

5.核心方法论：

核心方法论要和contribution对应上并且要明确解决的是哪个子问题。需要明确给出：输入是什么、数据怎样流动、模型怎么训练、在线怎样作用，以及每一部分解决哪个子问题。核心方法论里需要有insight，那么这个insight是什么呢？第二部分是否可以算是insight？

5.1任务审计和数据契约：哪些 episode 可作为有效动作学习数据？

5.2上下文条件化的滤波器：如何从任务有效数据学习可部署滤波？

3.跨轮更新闭环：如何让已采数据改善后续采集？

6.实验设计怎么验证三个贡献：

实验必须把三种命题分开：

1. 协议是否可执行、数据是否可审计？这是 contribution 1 的 artifact / feasibility validation，不是“协议带来提升”的因果实验。
2. 从 A_action 学到的滤波器是否是可部署的、人机仍可控的滤波器？这是 contribution 2 的机制验证。
3. 反复用它收集和更新，是否在固定资源下提高有效示范产率？这是 contribution 3 的主因果验证。

ACT 是第四层、独立的 construct-validity study：它问“这些数据是否对一个冻结的下游行为克隆器仍有用”，不能替代前面任何一层，也不参与滤波器选择。

6.1 Contribution 1：数据契约的可执行性与审计验证

这个贡献不需要以“优于某个协议”的效果结论成立，但必须证明它不是纸面规则。对所有 trial 报告：

- manifest 和时间同步字段的完成率；
- 每一条拒绝记录能否被唯一归入 reference_invalid、visibility_invalid、record_incomplete、safety_abort、external_override、task_failure、successful_safe_return 或 out_of_distribution；
- A_action 准入逻辑的自动可重放性：同一 raw record 重跑 audit 得到相同结果；
- 按预声明配置单元的 attempted / admitted / rejected-by-reason / active-time 表；
- 公开或随附 schema、audit code、配置 manifest 和一个可复放的示例 episode。

它验证的是“哪些数据可被复现地用于训练”，不能得出“该契约本身提高成功率”这一结论。

6.2 Contribution 2：学习型滤波器的机制与可部署性验证

目的。 隔离“从同一初始 A_action 训练出的 F_static 是否比规则滤波 F_rule 更好地辅助遥操”，但暂不让后续重训练成为变量。 F_static 只用初始数据 D_0 训练一次，并在该实验中冻结。

比较对象。

- F_rule ：当前已复现并集成的规则式自适应滤波器；
- F_static ：仅由 $D_0.action$ 训练的上下文条件化学习滤波器；
- 可选 F_raw ：无学习辅助的原始遥操/最小安全投影，用来解释规则滤波本身的收益；若安全上不可接受，则只作为离线 replay 对照，不能进入在线比较。

所有条件共享相同机器人、传感器、参考、速度/加速度/碰撞限制、急停和人工接管规则。每位操作者在各条件下执行相同且随机化的配置单元，采用 counterbalanced / Latin-square session order；记录操作者和配置单元，避免把熟练度或简单配置误判为滤波器收益。

这层的主结局不是 ACT 成功率，也不是 jerk。主结局应是同一 trial budget 下的 A_action 准入率或 task completion rate，并同时以 all-attempt safety-event rate 为安全守门指标。它只支持“该 filter 可部署且有帮助”的中间结论。

机制诊断（不参与 A_action 准入）：

- 原始输入、滤波输出和实际执行动作间的延迟及跟随偏差；
- 速度、加速度、jerk、高频命令能量和停滞/振荡次数；
- 相对参考的进展、回退次数、完成时长；
- 最小碰撞距离、限位触发、急停、人工关闭/覆盖滤波器次数；
- 输入保真度和关键微调保留：在接近、对孔、插入三个阶段分别报告，防止“低 jerk”只是删除有效修正。

判据。 若 F_static 只降低 jerk 而 task-valid 准入未增加、延迟增加或人工覆盖增加，则 contribution 2 不能写成“改善数据采集”，最多只能报告平滑化现象。若其在相同安全边界下提高 task-valid 准入且不恶化守门结果，才可进入飞轮实验。

6.3 Contribution 3：固定资源下的跨轮数据飞轮主实验

实验从完全相同的初始数据 D_0 、配置分布和安全边界出发：

- F_rule ：全程固定规则滤波；
- F_static ：用 $D_0.action$ 训练一次后冻结；
- $F_flywheel$ ：第 r 轮只用截至 $r-1$ 轮的 A_action 训练或更新 F_r ，随后冻结执行第 r

轮。准入逻辑在第 0 轮前冻结，不能按结果调门。

固定资源。 各臂严格相同的操作者主动时间、trial / reset 上限、配置单元配额、起始抓持条件、传感器、场景随机化种子或匹配后的场景清单，以及安全 envelope 'active time 从操作者开始发控制命令计时；reset、系统故障和标注时间单独报告，不能悄悄从分母移除。人员熟练度用随机化条件顺序、跨操作者平衡和配置分层处理。

主结局。

```
yield = # A_action-admitted episodes / active operator minute
```

报告逐轮 yield 和累计 yield，而不是只报告最终一轮。主对比为 F_flywheel 对 F_static：前者排除“仅仅训练一次就足够”的解释；F_static 对 F_rule 则分离学习滤波和规则滤波的差异。

守门与反塌缩结果。 对所有 attempted episode 而非仅 A_action 报告：

- task completion rate 'safety-event / emergency-stop / override rate；
- 失败和拒绝原因分布；
- 每个配置单元的尝试数、接受数及覆盖下限达成情况；
- 配置覆盖、近重复率与动作多样性；
- 机制指标和操作者主动时间。

若 F_flywheel 的 yield 只通过放弃困难配置、减少微调或扩大风险换得，则主结论不成立，即使接受率上升。

分析。 episode 是相关样本，统计单元不能假定为独立时间步。预先定义 effect size 为每臂的 yield difference / ratio，并对 operator 和 configuration block 做分层 bootstrap 或 mixed-effects count model，报告置信区间；最终样本量由 pilot 中的 yield 方差和预期最小实际效应决定。主结局、配置配额、排除规则和停止规则应在采集前冻结。

6.4 ACT 下游效用验证：

它不验证滤波器在线控制性能，而检验同样采集预算下得到的数据是否更利于一个标准下游学习器。使用每个实验臂**相同 active-time budget 所获得的全部 A_action** 训练同一 ACT / LeRobot 配置：相同 observation 'action 表示、训练步数、augmentation、随机种子数和 checkpoint selection rule；任务从相同的已抓持初始状态开始。

在采集前冻结 in-distribution 和 held-out configuration split，并在所有臂的相同测试清单上报告：插入成功率、成功终止判据、安全事件与置信区间。可另做一个“等 episode 数”的重采样分析，以区分：

- **固定时间数据集更好**：混合了采集产率与数据效用；
- **固定 episode 数仍更好**：才支持所保留轨迹的分布/动作质量更有利于 ACT。

ACT 训练绝不反向影响 A_action 准入、F_flywheel 更新或运行时混合权重；否则会把一个特定模型的偏好写进数据定义。

6.5 结果解释与可保留 claim

观察到的结果	可以写的结论	不能写的结论
契约可重放、记录完整，但三个滤波条件无差异	数据协议可执行且可审计	数据飞轮或学习滤波提升采集
F_static 改善机制指标，但 yield 无提升	该模型改变了命令动态学	改善了示范采集效率
F_flywheel 在安全和覆盖守门不恶化下提高 yield	固定资源下提高 task-valid 示范采集产率	对任意模型或任意家庭场景普遍更好
yield 提升，ACT 也在固定时间数据集上提升	采集闭环和该冻结 ACT 协议下的下游效用一致	数据质量具有模型无关的普适提升
yield 提升，ACT 无提升	采集效率提升；ACT 效用未获支持	采到的数据对下游策略更好

7.叙事逻辑参考：最相近工作的脉络

没有一篇近三年顶会/顶刊论文同时研究“已抓持、可见、参考可行的精密插入”“任务审计准入”“从成功遥操记录训练因果命令滤波”“固定资源下的跨轮采集产率”。最接近的是以下几条研究路线的交集。它们决定本文应如何叙事，也限定哪些宽泛 claim 不能再写。

工作	问题如何提出	关键中间机制	证据链
PATO, RSS 2023, 论文	人工遥操昂贵，一名操作者通常只能控制一台机器人。	从已有示范训练层级 assistive policy；对已知的重复子任务自主执行，在 task / policy uncertainty 高时请求人输入，并允许人覆盖。	真实机器人 user study 的心理负荷与示范吞吐；多机器人仿真的人时吞吐；同等人时下 BC 成功率。
Robot Learning on the Job / Sirius, RSS 2023, 论文	不成熟自主策略在部署中会失败；人类接管既保证任务，也暴露策略薄弱状态。	将接管前机器人动作赋为低质量、人类示范和接管动作赋为高质量，以 intervention-derived weight 训练并持续更新自主策略。	仿真与真实接触丰富操作中的 policy success、收敛速度与记忆管理。
DPIIL, RA-L 2024, 论文	clearance-limited 任务中，未成熟策	从人类速度-方差提取其感知的精度需求，与 policy	aperture passing ring threading 与真实 UR5e

工作	问题如何提出	关键中间机制	证据链
	略可能碰撞，而精确环境模型未必可得。	epistemic uncertainty 相乘形成风险，再在高风险状态请求人接管并迭代训练。	装配的安全和效率。
JUICER, IROS 2024, 论文	少量示范不足以训练长时程、高精度装配策略。	在 bottleneck 附近生成局部纠正轨迹、做仿真数据扩增，并将成功 policy rollout 回流重训。	四个仿真家具装配任务上的 imitation / augmentation 比较。
MimicGen, CoRL 2023, 论文	大规模人类示范昂贵，且有限示范不能覆盖广泛配置。	以对象中心变换和子任务组合，将少量人工示范自动适配到新对象、布局和初始状态。	18 个任务、50K 合成示范，以及下游 imitation learning。